

An isometric illustration on a light blue background featuring various computer-related items: a line graph with three peaks in the top left; a blue server tower with a 'G' logo and status lights; a tablet displaying a user interface with icons and a bar chart; a detailed motherboard with RAM sticks and a CPU; a 3.5-inch hard drive; and a blue USB drive with a white '\$\$' symbol.

# Predicción de rendimiento SIMCE mediante IDPS

GRUPO 1

Daniel Shinya  
Alexis Lema  
Sebastián Alonzo  
Alexander Berríos  
Bastian Lobos  
Diego Escobar



# El problema

Los Resultados SIMCE son el principal indicador académico del país

Factores externos a lo académico, tales como motivación o convivencia escolar pueden influir en el rendimiento.

A día de hoy no existen modelos predictivos de resultados académicos que utilicen IDPS

# ¿Porqué?

**Permite  
entender la  
relación entre  
bienestar y  
desempeño  
academico**

**Apoya la toma  
de decisiones  
políticas  
educativas  
basadas en  
evidencia  
comprobable**

**Facilita la  
detección de  
establecimien  
tos con riesgo  
académico de  
forma  
temprana**



# Objetivo general

Desarrollar un modelo  
de regresión capaz de  
predecir puntajes  
SIMCE utilizando  
indicadores IDPS y  
variables contextuales






# Objetivos específicos

Analizar relación  
entre indicadores  
IDPS y resultados  
SIMCE

Construir un  
modelo  
predictivo  
basado en  
regresión

Evaluar la  
precisión del  
modelo  
mediante  
métricas como  
RMSE y  $R^2$

Identificar  
variables que  
tienen mayor  
influencia en el  
rendimiento  
académico





Metodología basada en OSEMN

Enfoque en regresión supervisada

Variables predictoras: IDPS y contexto socioeconómico

Variable objetivo: Puntaje SIMCE

# Enfoque metodológico

# Datos Utilizados

Fuente:

Agencia de Calidad de la Educación

Resultados SIMCE

Indicadores de Desarrollo Personal y Social (IDPS).

Variables de vulnerabilidad y contexto escolar

Datos públicos oficiales de la agencia de calidad de la educación





# Preparación de datos

Integración de bases SIMCE, IDPS y contexto escolar.

Eliminación de registros con valores faltantes críticos.

Codificación de variables categóricas relevantes.

Definición de variable objetivo y variables predictoras.





# Preparación de datos

## Cobertura


- 9 años: 2016 – 2025 (excluyendo años de pandemia)
- 4 niveles evaluados: 4° básico, 6° básico, 8° básico y II medio

## Desafíos detectados

- Formatos mixtos: .csv y .txt
- Tres delimitadores distintos: coma, pipe (|) y punto y coma (;)
- Encoding inconsistente: Latin-1 vs UTF-8

¿Por qué importa?

Sin detección automática de formato, un solo archivo mal leído contamina años completos de datos y rompe la trazabilidad histórica.



# Drifts estructurales

Cambio de formato impuesto por la Agencia

Antes (2016 – 2022): formato Wide

- Una columna por indicador IDPS (ind\_am, ind\_cc, ind\_hv, ind\_pf)

Desde 2023: formato Long

- Una sola columna "ind" con el nombre del indicador
- Una columna "prom" con el valor → filas derretidas por colegio

¿Por qué importa?

Sin homologar la estructura, el modelo vería las mismas variables como columnas distintas y la matriz quedaría >80% en NaN, inutilizable para regresión.

# Limpieza Consolidación

**Nuestra variable a predecir:** Puntajes SIMCE de **Matemática** y **Lectura**.

## 1. Limpieza del target

- Dropna estricto en prom\_mate\_rbd y prom\_lect\_rbd
- Sin Y no hay aprendizaje supervisado: filas sin puntaje contaminan la validación cruzada y sesgan métricas
- Posible justificación de reducción del dataset: La pérdida de registros corresponde a establecimientos con notas en blanco o censuradas por secreto estadístico.

## 2. Estrategia de fusión

- Merge horizontal: une indicadores y sub-dimensiones por (rbd, año, curso)
- Append vertical: consolida toda la historia 2016 – 2025
- Deduplicación final por llave compuesta

## 3. Output: dataset maestro

- Datasets consolidados de IDPS y SIMCE listos para cruzar
- Diccionarios de datos en Markdown (idps + simce) para gobernanza y reproducibilidad

```
Procesando: simce2m2024_rbd_preliminar.csv
Procesando: simce2m2025_rbd_preliminar.csv
Procesando: simce2m2016_rbd_publica_final.csv
Procesando: simce2m2022_rbd_final.csv
Procesando: simce4b2024_rbd_preliminar.csv
Procesando: simce4b2025_rbd_preliminar.csv
Procesando: simce4b2016_rbd_publica_final.csv
Procesando: simce4b2022_rbd_final.csv
Procesando: simce6b2024_rbd_preliminar.csv
Procesando: simce6b2016_rbd_publica_final.csv
Procesando: simce8b2025_rbd_preliminar.csv
Procesando: simce4b2023_rbd_público_final.csv
Procesando: simce2m2023_rbd_público_final.csv
Procesando: simce2m2017_rbd_publica_final.txt
Procesando: simce2m2018_rbd_publica_final.txt
Procesando: simce4b2017_rbd_publica_final.txt
Procesando: simce4b2018_rbd_publica_final.txt
Procesando: simce6b2018_rbd_publica_final.txt
Procesando: simce8b2017_rbd_publica_final.txt
Procesando: simce8b2019_rbd.csv
```

```
--- Resumen de Limpieza ---
```

```
Total registros obtenidos: 111650
```

```
Registros sin Target eliminados: 57993
```

```
Total registros limpios para modelo: 53657
```



# Resultados de la fase Obtain & Scrub

## 1. Dataset IDPS consolidado

- 110.211 filas × 57 variables
- Cobertura: 8 años (2016, 2017, 2018, 2019, 2022, 2023, 2024, 2025)
- 4 niveles: 4° básico, 6° básico, 8° básico, II medio
- Incluye índices, sub-dimensiones y variables de contexto

## 2. Dataset SIMCE consolidado

- 53.657 filas × 7 variables
- Cobertura: 5 años con SIMCE rendido (2018, 2019, 2023, 2024, 2025)
- Variables: rbd, año, puntajes mate/lectura, GSE, dependencia, ruralidad

## Siguiente paso (en curso)

- Cruce IDPS × SIMCE por (rbd, año) para obtener el dataset analítico
- Reemplaza al dataset histórico reducido usado en la versión preliminar del notebook, ampliando años y registros disponibles para el modelo

¿Por qué importa?

Tener las dos bases consolidadas y limpias por separado permite recombinarlas con distintas estrategias (qué años incluir, cómo tratar nulos, etc) sin volver a tocar los archivos crudos.







# Alcance del Dataset Preliminar

## Estado Actual del Dataset (Versión Preliminar)

Para esta iteración, se construyó un dataset preliminar para validar el pipeline (OSEMN) y los modelos base.

- El foco específico es exclusivamente 2° Medio durante Años 2017 a 2024.
- Se consolidaron cientos de variables crudas en una matriz final de exactamente 11 columnas clave, por ejemplo:
  - ind\_am: Autoestima académica y motivación escolar.
  - ind\_cc: Clima de convivencia escolar.
  - ind\_hv: Hábitos de vida saludable.
  - ind\_pf: Participación y formación ciudadana.

Se debe escalar este mismo cruce para integrar niveles de básica (4°, 6°, 8° básico) y la totalidad del histórico de años, expandiendo los registros.





# Modelo propuesto

Modelo principal: Regresión lineal múltiple

Evaluación mediante validación cruzada.

Interpretación de variables con feature importance




# Alcance del proyecto

Análisis a nivel de establecimientos  
educacionales

Uso de datos históricos entre 2017 y 2025 (Excluyendo  
los años en donde no se realizó por pandemia)

No busca establecer causalidad, sino relaciones  
predictivas





# Resultados esperados

## Resultado 1

Predecir el  
rendimiento  
académico con  
variables socio-  
emocionales



## Resultado 2

identificar  
factores clave  
asociados a  
mejores  
resultados

## Resultado 3



generar  
evidencia útil  
para  
decisiones  
educativas

# Resultados preliminares





# Resultados preliminares



# Resultados preliminares

| Métrica  | Matemática | Lectura |
|----------|------------|---------|
| MAE      | 19.64      | 13.19   |
| RMSE     | 25.81      | 17.09   |
| $R^2$    | 0.592      | 0.557   |
| $R^2$ CV | 0.595      | 0.547   |

En matematica se obtuvo un  $R^2$  de 0.592 indica que el modelo explica el 59.2% de la variabilidad en los puntajes SIMCE entre establecimientos.

En lenguaje, se indica que el modelo explica el 55.7% de variabilidad.



El proyecto busca entregar un enfoque claro y enfocado en regresión predictiva

La integración de IDPS y SIMCE puede aportar información relevante para el sistema educativo chileno

# Conclusión

# Gracias

